RESEARCH QUESTION

Federated LEM2：Rule Conflict、Population Correction 與 Redundancy Asymmetry

erated LEM2 中，client fragmentation 如何透過 rule structure、support redundancy 與 conflict，改變 prediction policy 的結果

Client Fragmentation | Rule Structure | Conflict | Support Redundancy | Redundancy Asymmetry | Prediction Policy | Performance

本輪新增：**6-policy experiment · 15 target backtrace · 908 conflict occurrences**

PR #5 維持 Draft / Open / Not merged

這次更新了什麼

從「四種 policy 比較」往下挖到 population-level mechanism

80 / 20

20% holdout 不參與 reduct / LEM2 / support / we

6

4 baseline + 2 population variants

15

三個資料集各 5 個 target cases

908

C=2~5 的全部 conflict occurrences

新增核心量

T_d = support occurrences
U_d = unique supporting population
P_d = U_d / T_d

研究焦點改變

不是再加□多 voting，而是回答:
「同一批 population 被多條 rule 重複計價時，何時修正有效? 何時會 over-correct？」

這張圖要證明:

研究問題已從 policy ranking 收斂到 support redundancy 與 redundancy asymmetry。

End-to-End Pipeline

六種方法共用同一個 frozen artifact，只在最後 prediction layer 分岔

Decision Table
attrs + decision

80/20 Split
20% untouched

Client Partition
C=2,3,4,5

Local LEM2
local rules

UNION Aggregation
R_G=∪R_c

Conflict Audit
prediction-time

6 Policies
same test set

Training only

reduct · discretisation · local LEM2 · support · weight

Aggregation only

UNION 保留 antecedent + decision identity，不重新訓練

Holdout only

prediction · Accuracy · Recall · F1 · BA · Overall / Target Coverage

這張圖要證明：

C 是外層實驗因素；UNION 只做 aggregation；conflict resolution 發生在 prediction policy。

Conflict：先分 Candidate Generation，再分 Candidate Ranking

有些錯誤不是 voting 問題，而是 true class 根本沒有 matching rule

$$M(x) = \{ r \in R_G : x \text{ matches } Ante(r) \}$$

$$C_{conflict} = \{ x : |\{ d_r : r \in M(x) \}| > 1 \}$$

Layer A · Candidate Generation / Coverage

true class □否至少有一條 matching rule？

□ true class 不在 candidate decisions 中，任何 voting / population weighting

Layer B · Candidate Ranking / Conflict Resolution

多個 candidate decisions 同時存在時，哪個應該贏？

六種 prediction methods 的差異只發生在這一層。

這張圖要證明:

先區分「沒有正確 candidate」與「candidate 排序錯」，才能知道該修 induction 還是 scoring。

四個既有 Prediction Policies

四個 baseline 使用四種不同層次的 evidence

FIRST_MATCH

Order · 第一條 matching rule 決定答案 · Woźniak et al. (2026)

SIMPLE_VOTING

Rule Count · one matching rule = one vote · Lazo-Cortés et al. (2020)

STANDARD_VOTING

Support Sum · Σ |S(r)| · support overlap 會重複計數

GLOBAL_STRENGTH

Unique Coverage · |∪S(r)| / N_d · Bazan et al. (2000)

Order → Rule Count → Rule Support Sum → Unique Class Coverage Ratio

為什麼 **Standard** 會「重複放大」 **support**

同一 training object 若被多條 same-decision rules cover，會被重複加進 score

Matching rules for class A

r1 → A : {u1, u2, u3}
r2 → A : {u2, u3, u4}

u2、u3 同時支持 r1 與 r2

STANDARD_VOTING

|S(r1)| = 3
|S(r2)| = 3

Score_STD(A|x) = 3 + 3 = 6

Unique population

S(r1) ∪ S(r2) = {u1,u2,u3,u4}

真正不同的 supporting objects = 4

重複量 = T_A - U_A = 6 - 4 = 2

問題不是「support 大不大」，而是「support occurrences 中有多少其實是同一批 population 重複出現」。

這張圖要證明:

Standard 以 rule 為加總單位，因此 support overlap 會造成 evidence inflation。

Population Correction： T / U / P

兩個方法是 project-defined experimental variants，不宣稱來自既有文獻

T_d · Support Occurrences

$T_d = \Sigma |S_G(r)|$

保留每一條 rule 的 raw support 次數

U_d · Unique Population

$U_d = |\cup S_G(r)|$

同一 training object 只算一次

P_d · Nonredundancy

$P_d = U_d / T_d$

例: 4 / 6 = 2 / 3

POPULATION_STANDARD

$Score\_PS(d|x) = U_d$

把 Standard 的 duplicate support inflation 直接去重。

POPULATION_GLOBAL

$Score\_PG(d|x) = (U_d / N_d) \times (U_d / T_d)$

$= U_d^2 / (N_d T_d)$

這張圖要證明: Population correction 的目的不是保證更準，而是降低同一批 population 被多條 rule 重複計價的影響。

Experimental Design

三個 UCI datasets × 四個 client counts × 六種 methods = 72 組 holdout 結果

Dataset metadata

Hayes-Roth: 132 rows · 4 attrs · 3 classes · 106/26
Car Evaluation: 1,728 · 6 attrs · 4 classes · 1,382/346
Balance Scale: 625 · 4 attrs · 3 classes · 499/126

4

C = 2,3,4,5

6

Prediction methods

72

dataset × C × method

固定比較條件

同一 dataset · 同一 seed42 split · 同一 client partition · 同一 frozen rule artifacts

最後只看 **20%**

Accuracy · Recall · Macro-F1 · BA · Overall Coverage · Target Coverage

這張圖要證明:

六種方法的差異不來自資料切法，而是同一 conflict evidence 的 scoring semantics。

Six-Policy Results：沒有 Universal Winner

Population correction 在部分設定改善，但不是全面性 accuracy upgrade

Hayes-Roth

C2：多方法並列 0.7667
C3： FIRST_MATCH 0.8333
C4： FIRST_MATCH 0.7778
C5： FIRST_MATCH 0.8333

PG C5 = 0.6333，較 GS 0.7333 明顯下降

Car Evaluation

C2： GLOBAL / PG = 0.7174
C3： PG = 0.8005 最佳
C4： GLOBAL = 0.6832
C5： PG = 0.6338 最佳

Population Global 在 C3、C5 有正向改善

Balance Scale

C2： PS = 0.5632 最佳
C3： STD / PS = 0.5862
C4： STD / PS = 0.5977
C5： GS / PG = 0.5908

Population Standard 在部分設定改善或打平

這張圖要證明:

Population correction 是條件式修正；效果取決於 competing decisions 的 support redundancy 結構。

Target Backtrace：從整體分數回到單筆 evidence

三個資料集各挑 5 個代表性 holdout cases，另外再掃全部 conflict cases

1

Factors

保留因素值

2

Rules

列 matching rules

3

Decisions

分 candidate decision

4

T / U / P

回查 redundancy

5

6 Predictions

比較 winner

15

selected target cases

908

all conflict occurrences

43

winner changes from PS + PG

這張圖要證明:

目標不是再追一個更高 BA，而是解釋「為什麼這一筆被修正、另一筆被修壞」。

Balance Scale：同一去重機制，可以救對也可以修壞

關鍵不是 redundancy 是否存在，而是 redundancy 落在正確 decision 還是錯誤 competitor

Target 1 · CORRECTED

True = R

Standard： L=19 > R=18 → 錯
L： T=19, U=16
R： T=18, U=18

PS： L=16 < R=18 → 正確 R

Target 3 · HARMED

True = L

Standard： L=21 > R=19 → 正確
L： T=21, U=17
R： T=19, U=19

PS： L=17 < R=19 → 錯誤 R

這張圖要證明:

重複 evidence 不等於錯誤 evidence；若 true decision 本身高度重複，Population correction 可能 over-correct。

Car Evaluation：最清楚的成功與 Over-correction 例子

Population correction 會重新排序 candidate decisions，而不是增加新的 rules

Target 1 · PS CORRECTED

True = vgood
Standard： good=9， vgood=9
good： T=9, U=7
vgood： T=9, U=9

PS： good=7 < vgood=9
→ 修成 vgood

Target 2 · PG CORRECTED

True = good
GS(acc)=0.1140 > GS(good)=0.0909
acc： T=50, U=35, P=0.70
PG(acc)=0.0798
PG(good)=0.0909
→ acc 改判 good

Target 4 · PG HARMED

True = acc
GS(acc)=0.1270 > GS(unacc)=0.1095
acc： T=67, U=39, P=0.5821
PG(acc)=0.0739
→ 被 unacc 反超

這張圖要證明:

如果 repeated support 本來就是有效證據，Population penalty 就可能造成 over-correction。

Hayes-Roth：小樣本下的 Over-correction 風險最明顯

重要反例：不能把 Population 方法包裝成 universal improvement

Target 1 · PS 成功

True = class 3
錯誤 class 1： T=10 → U=7
真實 class 3： T=9 → U=9

PS： 7 < 9 → 修正成功

Target 2 · PS 修壞

True = class 1
真實 class 1： T=15 → U=8
class 2： T=9 → U=9

PS： 8 < 9 → 原正確結果被翻掉

-10.0 pp

Hayes C5： GS 0.7333 → PG 0.6333

目前只能形成機制假說

small local sample + high overlap 可能讓 redundancy penalty 過度懲罰有效 support；需要 repeated seeds / splits 才能正式驗[

這張圖要證明：

方法行為合理，不代表方法在每個資料條件下都會提升 performance。

有些 Case 根本不是 Scoring 問題

若 true class 沒有 matching rule，六種方法都只是在錯誤 candidates 中重新排序

Balance Target 5

True = B
Candidate decisions = {L, R}

B 不在 matching-rule decisions 中。
PG 即使把 R 改成 L，兩者仍都不是 B。

Car Target 5

True = good
Candidate decisions = {acc, vgood}

good 沒有 matching rule。
Population correction 只能換錯誤 winner。

Coverage / Induction Error ≠ **Conflict Ranking Error**

Target Coverage 看「有沒有 rule 能處理該 class」；Recall 才看「最後有沒有判對」。

這張圖要證明: 先把 candidate generation 與 candidate ranking 拆開，才能避免把所有錯誤都歸咎於 voting。

908 個 Conflict Occurrences：Population 只改少數 Borderline Cases

大部分 conflict cases 的 winner 沒變；真正變動集中在 redundancy 足以翻轉排序的 cases

Status counts

Balance · PS： Corrected 3 / Harmed 1 / Other 1 / Unchanged 261
Balance · PG： Corrected 3 / Harmed 3 / Other 3 / Unchanged 257
Car · PS： Corrected 2 / Harmed 4 / Unchanged 592
Car · PG： Corrected 7 / Harmed 6 / Other 1 / Unchanged 584
Hayes · PS： Corrected 1 / Harmed 4 / Unchanged 39
Hayes · PG： Corrected 0 / Harmed 4 / Unchanged 40

908

conflict occurrences

43

winner changes

PS changed = 16
PG changed = 27

這張圖要證明:

Population correction 不會重洗全部 conflict；它只影響少數 scoring margin 接近的 cases。

最重要的 Mechanism Check：43 / 43

所有被 Population correction 改變的 winner，都往 support redundancy 較低的 decision 移動

43 / 43

changed winners → lower-redundancy decision

這證明了什麼?

Population correction 確實降低重複 evidence 的 scoring influence。

但它只證明「在做去重」，不代表「去重一定提升真實分類」。

成功修正

錯誤 competitor redundancy 高於 true decision

Over-correction

true decision 自己的有效 evidence 更重複

Coverage failure

true decision 不在 candidate set；weighting 救不了

這張圖要證明:

方法確實執行去重，但「去重是否值得」取決於 redundancy 的位置。

真正值得研究的是 Redundancy Asymmetry

不是單看 P_d，而是比較 true decision 與 competing decision 誰更依賴重複 support

A(x) = Redundancy_competitor − Redundancy_true

A(x) > 0

錯誤 competitor 的 evidence 更重複

Population penalty 比較可能壓低錯誤 winner
→ CORRECTED

A(x) < 0

true decision 的 evidence 更重複

Population penalty 可能把有效 evidence 一起壓低
→ HARMED / over-correction

Redundancy ≠ Need

Redundancy Asymmetry = 下一個 mechanism variable

這張圖要證明:

下一輪應用 repeated seeds 驗證 asymmetry 是否穩定預測 corrected / harmed，而不是再加第七種 voting。

目前整體結論

從「哪個 policy 最好」進一步變成「什麼 evidence structure 讓哪個 policy 有效」

1

UNION 不解決 conflict

真正影響分類的是 prediction-time competing decisions。

2

沒有 universal winner

最佳 method 依 dataset、C、rule structure 與 conflict workload 改變。

3

Standard 的確會重複計價

support occurrences 與 unique supporting objects 是兩個不同概念。

4

Population 是條件式修正

能壓掉錯誤 redundancy，也可能懲罰有效 repeated evidence。

5

Coverage 與 Ranking 必須分開

true class 缺席時，任何 scoring policy 都無法救回。

6

核心是 redundancy asymmetry

43/43 changed winners 都往 redundancy 較低的 decision 移動。

這張圖要證明:

目前最站得住腳的貢獻不是「新方法一定更準」，而是揭示 support redundancy 的作用與限制。

下一步：把 Mechanism Evidence 變成 Statistical Evidence

目前 seed42 / single 80-20 split 可形成假說，但還不能做強因果或顯著性主張

1 · Repeated seeds / splits

每 dataset × C × policy 輸出 conflict cases

2 · Asymmetry features

true / competitor redundancy + consensus

3 · Statistical tests

paired Wilcoxon；避免把 test rows 當 algorithm-le

Research question

tion 如何透過 rule structure 與 redundancy asymmetry，改變 conflict-resolutio

Repository state

Jimmy0307/LEM2
branch: research/conflict-client-sweep-20261020
PR #5: Draft · Open · Not merged

這張圖要證明：

下一步先驗證 redundancy asymmetry；不要再增加 method，避免研究主軸被 voting variants 稀釋。