Federated LEM2： 把上次老師的問題逐題回答完整

資料規模 → 80/20 → 六方法 → Coverage → Standard / Global 改前改後 → 3×5 Target 回查 → 錯誤分解

3	6	15	908
UCI datasets	prediction methods	target backtraces	conflict occurrences

這一版不先談「新發現」，而是先把老師上次每一題用 code → evidence → result 回答完。

老師上次到底問了什麼?

本版簡報的順序完全照這張 checklist

1. 三份資料有幾筆? 幾個 headers / factors ?
2. 80/20 怎麼切? 20% 有沒有參與建模?
3. 同一資料跑六種方法， Acc / Recall / F1 到底是多少?
4. Overall Coverage 、 Target Coverage 到底是多少?
5. **Standard 的 3+3 為什麼有問題? 改完 A/B 誰贏?**
6. **Global 改法和原 GlobalStrength 差在哪? winner 怎麼變?**
7. **每個 dataset 的 Target 1–5 回查後，差別到底在哪?**

結論: 後面的 Redundancy Asymmetry 只能放在「回答完老師」之後，不能反過來取代老師的問題。

1. 資料規模： Rows 、 Headers 、 Factors 全部明列

Headers = condition attributes + 1 decision column

Dataset	Rows	Headers	Factors	Decision	Classes	Train 80%	Test 20%
Balance Scale	625	5	4	class	3	499	126
Car Evaluation	1728	7	6	class	4	1382	346
Hayes-Roth	132	5	4	class	3	106	26

Hayes-Roth

132 rows ・ 5 headers
4 factors + 1 decision ・ 3 classes

Car Evaluation

1,728 rows ・ 7 headers
6 factors + 1 decision ・ 4 classes

Balance Scale

625 rows ・ 5 headers
4 factors + 1 decision ・ 3 classes

結論： 老師問的「資料比數＋標頭量」現在由程式自動輸出，不再只寫 Attrs 。

2. 80 / 20： 最後 20% 完全不參與前面建模

同一 split 被六種方法共用；這是 final prediction set ，不是 training accuracy

100% Dataset

原始 decision table

80% Train

唯一可以學習的資料

Reduct → Clients → LEM2 → UNION → Support / Weight

全部在 80% 內完成

20% Holdout

最後才拿來 prediction

Evaluation

Acc ・ Recall ・ F1 ・ BA ・ Coverage

20% 不可以做的事

× reduct selection
× local LEM2 induction
× UNION support construction
× voting weight fitting

20% 唯一做的事

✓ matching / prediction
✓ Accuracy / Recall / Macro-F1 / Balanced Accuracy
✓ Overall / Target / Target Candidate Coverage

結論： 所有 reported prediction metrics 都只看 final 20%；不存在 test leakage 。

3. 同一個 frozen rule artifact 跑六種方法

前四個是既有 baseline；後兩個是本研究的 experimental variants

FIRST_MATCH

順序：第一條 matching rule

SIMPLE

rule count： 一條 rule 一票

STANDARD

support occurrences： $\Sigma|S(r)|$

GLOBAL

unique class coverage： $|\cup S(r)|/N_d$

POPULATION STANDARD

unique population： U_d

POPULATION GLOBAL

$(U_d/N_d) \times (U_d/T_d)$

Established baselines

Project-defined variants

結論： 六種方法的比較必須在相同 20% test 、相同 global rules 、相同 conflict cases 上進行。

4. Hayes-Roth： 六種方法的 20% Prediction Metrics

每個 cell = Accuracy / Balanced Accuracy(=Macro Recall) / Macro-F1

Method	C=2	C=3	C=4	C=5
FIRST	0.731 0.767 0.766	0.808 0.833 0.833	0.769 0.778 0.791	0.808 0.833 0.829
SIMPLE	0.654 0.656 0.679	0.654 0.611 0.617	0.577 0.567 0.595	0.577 0.522 0.503
STD	0.731 0.767 0.766	0.731 0.744 0.756	0.615 0.622 0.646	0.615 0.578 0.583
GS	0.731 0.767 0.766	0.692 0.733 0.733	0.692 0.733 0.731	0.692 0.733 0.731
PS	0.731 0.767 0.766	0.654 0.678 0.694	0.615 0.622 0.646	0.577 0.567 0.592
PG	0.731 0.767 0.766	0.654 0.733 0.733	0.615 0.700 0.699	0.577 0.633 0.625

cell 順序： Acc / BA(=Recall_macro) / Macro-F1

BA best → C2: FIRST/STD/GS/PS/PG 0.767 • C3: FIRST 0.833 • C4: FIRST 0.778 • C5: FIRST 0.833

結論： Accuracy 與 class-balanced 指標可能選出不同 winner； 不能只報一個 Accuracy。

4. Car Evaluation： 六種方法的 20% Prediction Metrics

每個 cell = Accuracy / Balanced Accuracy(=Macro Recall) / Macro-F1

Method	C=2	C=3	C=4	C=5
FIRST	0.899 0.664 0.658	0.905 0.674 0.682	0.887 0.631 0.630	0.873 0.596 0.607
SIMPLE	0.876 0.621 0.629	0.887 0.710 0.714	0.841 0.582 0.598	0.806 0.540 0.527
STD	0.902 0.669 0.672	0.910 0.709 0.708	0.879 0.593 0.635	0.858 0.544 0.568
GS	0.887 0.717 0.676	0.887 0.798 0.735	0.853 0.683 0.630	0.829 0.624 0.572
PS	0.905 0.689 0.687	0.908 0.706 0.700	0.879 0.591 0.628	0.853 0.537 0.562
PG	0.717 0.676	0.801 0.735	0.678 0.621	0.634 0.586

cell 順序： Acc / BA(=Recall_macro) / Macro-F1

BA best → C2: GS/PG 0.717 • C3: PG 0.801 • C4: GS 0.683 • C5: PG 0.634

結論： Accuracy 與 class-balanced 指標可能選出不同 winner； 不能只報一個 Accuracy。

4. Balance Scale： 六種方法的 20% Prediction Metrics

每個 cell = Accuracy / Balanced Accuracy(=Macro Recall) / Macro-F1

Method	C=2	C=3	C=4	C=5
FIRST	0.675 0.489 0.504	0.651 0.471 0.488	0.706 0.511 0.510	0.675 0.489 0.484
SIMPLE	0.722 0.523 0.523	0.738 0.534 0.529	0.794 0.575 0.558	0.746 0.540 0.525
STD	0.770 0.557 0.544	0.810 0.586 0.564	0.825 0.598 0.573	0.778 0.563 0.542
GS	0.738 0.534 0.537	0.786 0.569 0.555	0.810 0.586 0.571	0.778 0.591 0.591
PS	0.778 0.563 0.550	0.810 0.586 0.564	0.825 0.598 0.573	0.786 0.569 0.548
PG	0.534 0.537	0.575 0.560	0.580 0.565	0.591 0.590

cell 順序： Acc / BA(=Recall_macro) / Macro-F1

BA best → C2: PS 0.563 • C3: STD/PS 0.586 • C4: STD/PS 0.598 • C5: GS/PG 0.591

結論： Accuracy 與 class-balanced 指標可能選出不同 winner； 不能只報一個 Accuracy。

5. Coverage： 要拆成三個問題

這是本次補 code 後最重要的新區分

Overall Coverage

整個 20% test 中，有沒有任何 rule match？

$|\{x : M(x) \neq \varnothing\}| / |U_{test}|$

Target Coverage

真實屬於 class d 的 test cases 中，有沒有任何 rule match？

不要求 matching rule 的 decision=d

Target Candidate Coverage

真實屬於 class d 的 test cases 中，是否至少有一條 matching rule 真的提出 d？

這才偵測「true class 根本沒進 candidate set」

Coverage ≠ Recall

Coverage 問「能不能進決策」； Recall 問「最後有沒有判對」。

為什麼要多這一層?

真實 B 可能有 rule match，但 matching rules 只有 L / R。舊 Target Coverage 會算 covered； Target Candidate Coverage 才會判斷 B 沒有被產生。

結論： Candidate Generation / Coverage failure 與 Candidate Ranking / Conflict error 必須分開。

6. 三個 UCI 的實際 Coverage

三個數字都由同一 20% holdout 自動計算；六種 policy 的 coverage 相同

Dataset	C	Overall	Target(any rule)	Target(candidate)
Balance	2	94.4%	93.2%	57.5%
Balance	3	98.4%	98.9%	61.5%
Balance	4	100.0%	100.0%	72.2%
Balance	5	99.2%	99.4%	67.1%
Car	2	97.7%	92.9%	80.9%
Car	3	98.3%	98.3%	91.0%
Car	4	99.4%	97.8%	95.0%
Car	5	100.0%	100.0%	87.3%
Hayes-Roth	2	92.3%	93.3%	73.3%
Hayes-Roth	3	100.0%	100.0%	93.3%
Hayes-Roth	4	100.0%	100.0%	86.7%
Hayes-Roth	5	100.0%	100.0%	93.3%

最大差距

Balance C=2： Target(any rule)=93.2%，但 Target(candidate)=57.5%；代表「有規則 match」不等於「真正 target class 有 candidate rule」。

Target Candidate Coverage： 真正暴露 induction / coverage gap

特別是 Balance 的 B class，舊 coverage 幾乎看不出問題

Balance Scale

C	Class	Any	Candidate
2	B	90.0%	0.0%
2	L	94.8%	84.5%
2	R	94.8%	87.9%
3	B	100.0%	0.0%
3	L	98.3%	94.8%
3	R	98.3%	89.7%
4	B	100.0%	20.0%
4	L	100.0%	98.3%
4	R	100.0%	98.3%
5	B	100.0%	10.0%
5	L	98.3%	94.8%
5	R	100.0%	96.6%

Balance B： C2=0%、C3=0%

Car Evaluation

C	Class	Any	Candidate
2	acc	93.5%	81.8%
2	good	85.7%	57.1%
2	unacc	100.0%	100.0%
2	vgood	92.3%	84.6%
3	acc	93.5%	93.5%
3	good	100.0%	78.6%
3	unacc	99.6%	99.6%
3	vgood	100.0%	92.3%
4	acc	98.7%	94.8%
4	good	100.0%	92.9%
4	unacc	100.0%	100.0%
4	vgood	92.3%	92.3%
5	acc	100.0%	93.5%
5	good	100.0%	71.4%
5	unacc	100.0%	99.6%

Car good： C2 只有 57.1%

Hayes-Roth

C	Class	Any	Candidate
2	1.0	90.0%	60.0%
2	2.0	90.0%	60.0%
2	3.0	100.0%	100.0%
3	1.0	100.0%	90.0%
3	2.0	100.0%	90.0%
3	3.0	100.0%	100.0%
4	1.0	100.0%	80.0%
4	2.0	100.0%	80.0%
4	3.0	100.0%	100.0%
5	1.0	100.0%	100.0%
5	2.0	100.0%	80.0%
5	3.0	100.0%	100.0%

Hayes C2： class1/2 都只有 60%

7. Standard：老師的「3+3」問題，現在完整算到 winner

核心不是把多的 u 當負分，而是避免同一 population 被 rule occurrences 重複放大

A 的兩條 rules

r1→A : {u1,u2,u3}
r2→A : {u2,u3,u4}

T_A = 3+3 = 6
U_A = 4
P_A = 4/6 = 2/3

若 B 的 evidence

假設 T_B = 5
而且五個 support 都不同

U_B = 5
P_B = 1

改前 vs 改後

STANDARD： A=6 > B=5 → A

POPULATION STANDARD：
A=U_A=4 < B=U_B=5 → B

Standard 看 T_d （occurrences） → Population Standard 看 U_d （unique objects）

結論： 新的 score 不會把「多出來的 unique u」扣分；它只是把重複出現的同一 u 從多次計價改成一次。

Standard 真實回查：同一機制可以 Correct，也可以 Harm

用 20% holdout 的真實 conflict case，不再只看 toy example

Corrected case · Car Target 1

True = vgood
STD winner = good → PS winner = vgood

old: T=9, U=7, P=0.778
new: T=9, U=9, P=1.000

CORRECTED · A(x)=0.222

Harmed case · Car Target 3

True = acc
STD winner = acc → PS winner = unacc

old: T=38, U=25, P=0.658
new: T=27, U=27, P=1.000

HARMED · A(x)=-0.342

Interpretation

同樣是去重：如果錯誤 competitor 的 redundancy 高，可能救回 true class；如果 true class 的 evidence 本身高度重疊，就可能 over-correct。

結論： Redundancy ≠ Noise。去重本身是明確行為，但「重複 evidence 是否該被懲罰」取決於它出現在誰身上。

8. Global： 原 GlobalStrength 再乘 Population Nonredundancy

不是把 numerator / denominator 真正倒過來；而是加一個 P_d=U_d/T_d correction

原 GlobalStrength

GS_d = U_d / N_d

U_d： unique support objects
N_d： training decision class size

Population factor

P_d = U_d / T_d

T_d： support occurrences
P_d 越低 → evidence overlap 越高

Population Global

PG_d = GS_d × P_d

= U_d^2 / (N_d T_d)

原本回答：「unique population 佔 class 多大?」 ＋ **新增回答：「這些 evidence 有多少不是重複計價?」**

結論： Population Global 是 experimental correction； GlobalStrength 本身仍保留為 baseline，不被覆蓋。

Global 真實回查： winner 怎麼被 P_d 改變

Car 的 corrected / harmed case 直接算出 old → new

Corrected • Car Target 2

True = good
GS winner = acc → PG winner = good

old winner: T=50, U=35, P=0.700
new winner: T=5, U=5, P=1.000

winner redundancy drop = 0.300
CORRECTED

Harmed • Car Target 4

True = acc
GS winner = acc → PG winner = unacc

old winner: T=67, U=39, P=0.582
new winner: T=106, U=106, P=1.000

winner redundancy drop = 0.418
HARMED

Key
所有 winner change 都往 redundancy 較低的 decision 移動；但較低 redundancy 不等於一定是真實類別。

結論： PG 的行為符合設計；真正的研究問題是何時這個 penalty 對「錯的人」施加、何時對「對的人」施加。

9. Balance Scale： Target 1–5 全部回查

不是挑幾筆漂亮案例； 5 個 selected holdout targets 全部列出

T	C	True	Factors	STD→PS	GS→PG	True cand?
1	2	R	right_distance=5.0, right_weight=1.0, left_distance=3.0, …	Corrected	Unchanged	YES
2	2	L	right_distance=3.0, right_weight=1.0, left_distance=5.0, …	Unchanged	Corrected	YES
3	3	L	right_distance=3.0, right_weight=1.0, left_distance=4.0, …	Harmed	Unchanged	YES
4	4	L	right_distance=5.0, right_weight=1.0, left_distance=4.0, …	Unchanged	Harmed	YES
5	4	B	right_distance=4.0, right_weight=1.0, left_distance=4.0, …	Unchanged	Changed / same correctness	NO

這 5 筆： corrected events=2 • harmed events=2 • true-candidate missing=1

9. Car Evaluation： Target 1–5 全部回查

不是挑幾筆漂亮案例； 5 個 selected holdout targets 全部列出

T	C	True	Factors	STD→PS	GS→PG	True cand?
1	2	vgood	buying=low, maint=low, doors=2.0, persons=4, lug_boot=big…	Corrected	Unchanged	YES
2	5	good	buying=med, maint=low, doors=3.0, persons=4, lug_boot=big…	Unchanged	Corrected	YES
3	5	acc	buying=med, maint=vhigh, doors=4.0, persons=more, lug_boo…	Harmed	Unchanged	YES
4	5	acc	buying=high, maint=low, doors=4.0, persons=4, lug_boot=sm…	Unchanged	Harmed	YES
5	3	good	buying=med, maint=low, doors=4.0, persons=4, lug_boot=sma…	Unchanged	Changed / same correctness	NO

這 5 筆： corrected events=2 • harmed events=2 • true-candidate missing=1

9. Hayes-Roth： Target 1–5 全部回查

不是挑幾筆漂亮案例； 5 個 selected holdout targets 全部列出

T	C	True	Factors	STD→PS	GS→PG	True cand?
1	5	3.0	hobby=2.0, age=3.0, educational_level=4.0, marital_status…	Corrected	Unchanged	YES
2	3	1.0	hobby=3.0, age=1.0, educational_level=1.0, marital_status…	Harmed	Unchanged	YES
3	5	1.0	hobby=2.0, age=1.0, educational_level=1.0, marital_status…	Unchanged	Harmed	YES
4	4	1.0	hobby=3.0, age=1.0, educational_level=2.0, marital_status…	Unchanged	Unchanged	YES
5	5	1.0	hobby=1.0, age=1.0, educational_level=3.0, marital_status…	Unchanged	Unchanged	YES

這 5 筆： corrected events=1 • harmed events=2 • true-candidate missing=0

10. 908 個 Conflict Occurrences： 把 error 拆開

Population correction 只改 43 個 borderline cases；另外有 45 個 conflict cases 的 true class 根本不在 candidate set

Dataset	Conflict	True cand absent	PS corrected	PS harmed	PG corrected	PG harmed
Balance Scale	266	35	3	1	3	3
Car Evaluation	598	10	2	4	7	6
Hayes-Roth	44	0	1	4	0	4

908
conflict occurrences

43
population-induced winner changes

45
conflict cases without true candidate

43/43
changed winner → lower redundancy

結論： Coverage / induction failure 不能用 voting 修； Ranking error 才是 Standard / Global / Population policies 能處理的範圍。

11. Redundancy Asymmetry： 現在已正式寫進 code 與 CSV

這是 mechanism diagnostic，不是既有文獻 metric，也不是獨立 causal proof

$$R_d = 1 - P_d \qquad A(x) = R_{competitor} - R_{true}$$

A(x) > 0 · Corrected-side mechanism

錯誤 competitor 的 evidence 比 true decision 更重複。
目前 corrected transitions 的 A(x) 全部為正。

A(x) < 0 · Over-correction-side mechanism

true decision 本身的 evidence 比錯誤 competitor 更重複。
目前 harmed transitions 的 A(x) 全部為負。

Method	Status	n	mean A	min	max
PS	CORRECTED	6	+0.181	+0.062	+0.300
PS	HARMED	9	-0.336	-0.467	-0.171
PG	CORRECTED	10	+0.187	+0.133	+0.300
PG	HARMED	13	-0.246	-0.418	-0.107

結論： A(x) 的 sign 在 changed cases 中是機制一致性檢查；下一步要在 repeated splits 中測它能否事前預測 corrected / harmed 。

12. 老師上次問題：現在逐題的最終答案

這頁就是開會最後要交卷的版本

資料量?	132/5 、 1728/7 、 625/5 （ Rows / Headers ），並明列 factors 、 classes 、 80/20 。
20% 有沒有參與?	沒有。 20% 只做最後 prediction / evaluation ；所有 rules / supports / weights 只由 80% 建立。
六種方法結果?	72 組完整 Acc / Recall(=BA) / Macro-F1 已自動輸出；沒有 universal winner 。
Coverage ?	Overall 、 Target(any rule) 、 Target Candidate(true class represented) 三層已分開。
Standard 3+3 ?	T_d 會重複計 support occurrences ； PS 改用 U_d ，只讓同一 supporting object 計一次。
Global 怎麼改?	保留 GS=U/N ，再乘 P=U/T ； $PG=U^2/(NT)$ 。 baseline 不被覆蓋。
Target 1–5 ?	三個 dataset 各 5 筆全部回查；可分 corrected 、 harmed 、 coverage failure 。

結論： 老師要求的每一題現在都有對應 code 、 CSV evidence 與簡報頁，不再靠人工口頭補。

13. Code / Evidence Closure

這次不是只改 PPT；缺的 diagnostics 已正式進 research branch

Code 補齊

✓ Target Candidate Coverage
✓ Redundancy Asymmetry helper
✓ Coverage vs Ranking error classification
✓ Standard / Global transition decomposition

Teacher CSVs

✓ dataset metadata
✓ six-policy metrics
✓ coverage by class
✓ target 1–5
✓ STD/GS transitions
✓ error/asymmetry tables

Verification

TDD RED：缺 function / module 時 CI fail
GREEN： implementation 後
118 tests passed ・ compile PASS
backtrace workflow SUCCESS

Repository state

Branch: research/conflict-client-sweep-20261020
PR #5: Draft / Open / Not merged
Frozen production main remains unchanged.

結論： 這一輪完成的是 professor-question evidence layer，不修改 frozen main，也不新增第七種 prediction policy。

14. 現在可以下什麼結論、還不能下什麼結論

把「已證明的 code 行為」與「下一步要統計驗證的研究假說」分開

目前可以確定

- Population correction 會降低 duplicated support 對 winner 的影響。
- 43/43 changed winners 都往 lower-redundancy decision 移動。
- 它可以 corrected，也可以 harmed。
- true class 不在 candidate set 時，任何 voting 都救不了。
- Target Candidate Coverage 能直接量到這個缺口。

目前不能直接宣稱

- Population method universally better。
- Client 數越多就一定越好／越差。
- Redundancy 本身就是 noise。
- A(x) 已經是 causal predictor。
- seed=42 的 72 rows 可直接當獨立樣本做顯著性。

下一步

Repeated matched seeds / splits → 每個 conflict case 記錄 candidate coverage、T/U/P、score margin、A(x) → Friedman / paired Wilcoxon（block-level）。

結論： 下一輪不加新方法；先驗證「什麼 support structure 會讓 Population correction corrected 或 over-correct」。